

Nome: André Machado Silva

Repositório no GitHub: <https://github.com/andrems1/onboarding-LIPAI>

Introdução a Aprendizagem de Máquina

Semana 7 / Atividade 1

Exercícios do Livro

Questão 5 — Descrição das terminologias: Generative AI e NLP

a) Generative AI (IA Generativa)

A IA Generativa é uma categoria de inteligência artificial focada na criação de novos conteúdos — como textos, imagens, áudios, vídeos e código — a partir de padrões aprendidos em grandes conjuntos de dados. Diferente dos modelos discriminativos, que apenas classificam ou preveem a partir de entradas existentes, modelos generativos são capazes de produzir saídas inéditas e coerentes.

Os principais exemplos de IA Generativa incluem modelos de linguagem de grande escala (LLMs) como o GPT-4 e Claude, que geram texto natural; modelos de difusão como o Stable Diffusion e DALL-E, que geram imagens a partir de descrições textuais; e GANs (Generative Adversarial Networks), que treinam dois modelos em competição para gerar dados cada vez mais realistas.

Aplicações práticas incluem geração de código de programação, criação de arte digital, síntese de voz, produção de conteúdo de marketing e assistentes virtuais conversacionais.

b) NLP — Natural Language Processing (Processamento de Linguagem Natural)

NLP é uma subárea da Inteligência Artificial que se dedica a capacitar computadores a compreender, interpretar e gerar linguagem humana de forma natural. É uma disciplina interdisciplinar, combinando linguística, ciência da computação e aprendizado de máquina.

Tarefas fundamentais de NLP incluem tokenização (divisão do texto em unidades menores), análise de sentimentos (identificar a polaridade emocional de um texto), reconhecimento de entidades nomeadas (NER), tradução automática, resumo automático de textos e respostas a perguntas (question answering).

Exemplos reais: tradutores automáticos como o Google Translate, assistentes de voz como a Siri e Alexa, sistemas de análise de avaliações de clientes em e-commerces e chatbots de suporte ao cliente.

Questão 8 — Habilidades essenciais para profissionais de Machine Learning

1. Fundamentos de Matemática e Estatística

Álgebra linear (vetores, matrizes, transformações), cálculo diferencial (gradientes, derivadas para otimização) e estatística (probabilidade, distribuições, testes de hipóteses) são a base teórica de todos os algoritmos de ML. Sem esses fundamentos, fica difícil compreender por que um modelo

funciona ou falha.

2. Programação em Python (e ferramentas de ecossistema)

Python é a linguagem dominante em ML. O profissional deve dominar bibliotecas como NumPy, Pandas, Scikit-learn, TensorFlow e PyTorch. Saber usar ambientes como Jupyter Notebook e Google Colab é essencial para experimentação e documentação.

3. Pré-processamento e Engenharia de Features

Grande parte do trabalho em ML está na preparação dos dados: limpeza, tratamento de valores ausentes, normalização, codificação de variáveis categóricas e seleção de features relevantes. Um modelo só é tão bom quanto os dados que o alimentam.

4. Conhecimento em Algoritmos de ML

O profissional deve conhecer os principais algoritmos supervisionados (regressão, árvores de decisão, SVM, redes neurais), não supervisionados (k-means, DBSCAN, PCA) e por reforço, sabendo quando e como aplicar cada um.

5. Avaliação de Modelos e Métricas

Saber interpretar métricas como acurácia, precisão, recall, F1-score, AUC-ROC, RMSE e MAE é fundamental. Também é necessário entender conceitos como overfitting, underfitting, validação cruzada e divisão treino/teste.

6. Comunicação e Visualização de Dados

Traduzir resultados técnicos para linguagem acessível a stakeholders não técnicos é uma habilidade muito valorizada. Ferramentas como Matplotlib, Seaborn e Tableau ajudam a comunicar insights de forma visual e clara.

7. Pensamento Crítico e Domínio do Problema

Entender o contexto do negócio ou área de aplicação é essencial para formular o problema corretamente, escolher as variáveis certas e interpretar os resultados de maneira significativa.

Questão 9 — Cinco aplicações reais de Machine Learning (com dois exemplos cada)

1. Saúde e Diagnóstico Médico

- **Deteção de câncer por imagem:** Modelos de deep learning, especialmente CNNs, são treinados com milhares de imagens de exames (mamografias, raios-X, tomografias) para identificar tumores malignos com precisão comparável ou superior à de radiologistas humanos. O sistema da Google (DeepMind) demonstrou desempenho equivalente ao de especialistas na detecção de câncer de mama.
- **Predição de doenças crônicas:** Algoritmos de ML analisam histórico clínico, exames laboratoriais e dados de estilo de vida para prever o risco de um paciente desenvolver diabetes tipo 2, hipertensão ou doenças cardiovasculares, permitindo intervenção preventiva.

2. Finanças e Deteção de Fraudes

- **Deteção de transações fraudulentas em cartões de crédito:** Bancos como Visa e Mastercard utilizam modelos de ML que analisam em tempo real padrões de comportamento do usuário (localização, valor, frequência) para identificar transações suspeitas e bloqueá-las antes que o prejuízo ocorra.

- **Análise de crédito e concessão de empréstimos:** Instituições financeiras utilizam modelos preditivos para avaliar o risco de inadimplência de um solicitante de crédito, considerando dados como histórico de pagamentos, renda, comportamento de consumo e dados alternativos.

3. Varejo e Sistemas de Recomendação

- **Recomendação de produtos na Amazon:** A Amazon utiliza filtros colaborativos e modelos baseados em conteúdo para sugerir produtos com base no histórico de compras, itens visualizados e comportamento de usuários similares. Estima-se que 35% das receitas da Amazon sejam geradas por seu sistema de recomendações.
- **Personalização de conteúdo na Netflix:** A Netflix combina aprendizado não supervisionado (agrupamento de usuários por preferência) e por reforço (adaptação contínua com base nas interações) para personalizar thumbnails, ordem de exibição e sugestões de séries e filmes.

4. Transporte e Veículos Autônomos

- **Carros autônomos (Tesla Autopilot, Waymo):** Veículos autônomos utilizam múltiplos modelos de ML para percepção (detectar pedestres, sinais, faixas), planejamento de trajetória e tomada de decisão em tempo real, integrando dados de câmeras, LiDAR e GPS.
- **Otimização de rotas e logística (Uber, iFood):** Plataformas de mobilidade e entrega usam ML para prever a demanda em diferentes regiões, otimizar rotas de entregadores e motoristas em tempo real, reduzindo tempo de espera e custos operacionais.

5. Processamento de Linguagem Natural (NLP)

- **Assistentes virtuais (Google Assistant, Alexa):** Assistentes de voz utilizam modelos de NLP para reconhecer fala, interpretar a intenção do usuário e gerar respostas naturais. Envolvem múltiplos estágios de ML: ASR (reconhecimento de fala), NLU (compreensão) e NLG (geração).
- **Análise de sentimento em redes sociais:** Empresas monitoram menções à sua marca em plataformas como Twitter e Instagram usando modelos de análise de sentimento para identificar crises de reputação, medir satisfação de clientes e avaliar a recepção de novos produtos.

Reflexões sobre os Tipos de Aprendizado e o Contexto Médico

Os três tipos de aprendizado de máquina — supervisionado, não supervisionado e por reforço — têm aplicações complementares no contexto médico, e compreender suas diferenças é fundamental para escolher a abordagem correta.

O aprendizado supervisionado é o mais utilizado na área da saúde quando há dados rotulados disponíveis, como imagens de exames com diagnósticos confirmados. Modelos treinados com esses dados conseguem classificar novas imagens ou prever riscos com alta precisão. O desafio principal é a necessidade de grandes volumes de dados rotulados, que muitas vezes são escassos e de difícil obtenção por questões de privacidade e custo.

O aprendizado não supervisionado é valioso quando não existem rótulos claros — por exemplo, para identificar subgrupos de pacientes com perfis clínicos similares (clustering) sem que se saiba previamente quais grupos existem. Isso pode revelar subtipos de doenças ainda não descritos na

literatura médica.

O aprendizado por reforço, embora menos explorado clinicamente, tem potencial para otimizar protocolos de tratamento personalizados, onde o modelo aprende, ao longo do tempo, qual sequência de intervenções maximiza a recuperação do paciente. Um desafio ético crítico nesse contexto é garantir que os erros cometidos durante o aprendizado não causem danos reais aos pacientes.

O contexto médico impõe desafios únicos ao ML: interpretabilidade dos modelos (médicos precisam entender o raciocínio da IA), viés nos dados históricos (que pode perpetuar desigualdades no diagnóstico), e a necessidade de validação rigorosa antes da implantação clínica. Apesar disso, o potencial de transformação é imenso, desde diagnósticos mais rápidos e precisos até medicina de precisão personalizada.